

Avaliação de critérios de otimalidade em um método de seleção de atributos em GWAS para classificação binária

Izabela da Silva Lopes

Orientação: Fabrízio Condé de Oliveira

Fevereiro de 2025

1 Introdução

Cada ser vivo, seja humano, animal ou vegetal, é constituído por um genoma que é o conjunto de toda informação genética contida em uma sequência completa de nucleotídeos que compõem o DNA de um organismo. O genoma é um código genético que permite determinar como um ser vivo se desenvolverá, no caso dos humanos, é formado por informações fundamentais para a caracterização do desenvolvimento físico do indivíduo. Seu interior é decomposto em sequências codificantes de DNA, também chamado de gene e sequências não codificantes de DNA. Os genes são as unidades básicas da hereditariedade, pois contém as informações genéticas que são passadas de pais para filhos, entretanto, extenso é o número de genes dentro de um genoma, cerca de 20.000 a 30.000 genes estão espalhados por todo genoma humano (LAIRD; LANGE, 2010).

O conjunto de genes que um indivíduo possui é chamado de genótipo que está relacionado com determinado fenótipo, fator que depende diretamente da combinação do genótipo e o meio-ambiente no qual o indivíduo se desenvolve. Os fenótipos são as características fisiológicas, morfológicas e comportamentais de um ser vivo. Pode ser entendido como características observáveis e não observáveis. A textura do pelo de um animal, o tipo sanguíneo de uma pessoa e a cor amarela de uma flor são alguns exemplos de fenótipos. Por meio dos genes relacionados a determinados fenótipos pode-se descobrir atributos benéficos de um ser vivo e até mesmo identificar genes relacionados a doenças, como por exemplo o câncer de mama (SETIAWAN; KUSUMA; WIGENA, 2018).

Estudos de associação genômica ampla (do inglês, *Genome Wide Association Studies* – GWAS) são realizados para identificar variações no genoma associadas a um fenótipo de interesse, isto é, é um método usado para encontrar associações entre polimorfismos genéticos e uma característica específica por meio de abordagens distintas. Os polimorfismos são variações genéticas que surgem como consequência de mutações. São variantes genéticas encontradas em um único locus, ou seja, encontrados no interior de um gene. Este local é citado como um polimorfismo de nucleotídeo único (do inglês, *Simple Nucleotide Polymorphism* - SNP) que é considerado como a unidade fundamental de análise (SETIAWAN; KUSUMA; WIGENA, 2018). Os SNPs são uma forma de variação genômica que se estabeleceram na população com uma frequência mínima de 1 % (BROOKES, 1999). Marcadores do tipo SNP permitem a geração de inúmeras informações sobre a variabilidade genética ao nível do DNA. Por consequência, faz-se necessário a utilização de métodos específicos para mapear cada marcador genético que tem variação em uma população que pode estar relacionada com o fenótipo de interesse, a partir disso, o presente trabalho busca utilizar de um método para que essa busca seja eficiente computacionalmente e que gere SNPs verdadeiramente associados a variações fenotípicas.

2 Justificativa

Ínúmeros são os estudos sobre GWAS, visto que auxiliam na descoberta e compreensão de diversas doenças. Ao observar a Figura 5 abaixo, podemos compreender que a área genômica tem crescido exponencialmente durante anos e a partir desse crescimento observar a importância dessa área de pesquisa.




Figura 1 – Número de publicações sobre GWAS entre 2005 e 2012.

National Human Genome Research Institute-NHGRI. Adaptado de Welter et al. (2014)

Por meio de subgrupos de SNPs selecionados por algum método, pesquisadores são capazes de estudar como determinadas doenças operam e também saber se um novo indivíduo tem determinada doença (LO et al., 2015), o que torna um trabalho ainda mais notável.

Uma aplicação prática deste trabalho, utilizando bases de dados reais, está na identificação de genes relacionados ao risco de desenvolvimento de doenças humanas. Isso é possível ao selecionar marcadores SNPs causais pelo método proposto e examinar os genes nas proximidades desses marcadores. Esses genes podem tanto aumentar quanto reduzir o risco de doenças complexas, contribuindo para uma compreensão mais profunda dos fatores genéticos associados a essas condições.

Os estudos de GWAS frequentemente utilizam abordagens baseadas em problemas de classificação para identificar associações entre variações genéticas e características fenotípicas. Isso se deve à natureza binária de muitas condições analisadas, como presença ou ausência de doenças. Esse método permite categorizar indivíduos em diferentes grupos fenotípicos com base em suas características genômicas, facilitando a identificação de variantes genéticas associadas a determinado fenótipo (BUSH; MOORE, 2012; VISSCHER et al., 2017). No entanto, estudos de GWAS do mundo real podem sofrer com o problema de desequilíbrio de dados de amostras. Esse problema de desequilíbrio pode causar sérios vieses no resultado e, portanto, leva a perdas de significância para marcadores causais verdadeiros.

No campo da ciência de dados, lidar com bases de dados desbalanceadas é um dos maiores desafios em problemas do mundo real, especialmente em aplicações na área da saúde. Em muitos cenários, o objetivo principal é detectar condições específicas que, geralmente, afetam uma parcela reduzida da população. Por exemplo, diagnósticos de câncer de mama ou diabetes frequentemente enfrentam o problema de dados desbalanceados, onde os exemplos da classe minoritária são insuficientemente representados. Esse desequilíbrio impacta o desempenho dos modelos preditivos, pois os algoritmos de aprendizado de máquina, em sua maioria, são projetados para trabalhar com dados balanceados, levando a baixos índices de acurácia na identificação das classes menos prevalentes (KRAWCZYK, 2016). Um exemplo é a simulação 6 (OLIVEIRA, 2015) que foi desenvolvida para explorar o uso do método SMS adaptado para problemas de classificação binária. O conjunto de dados utilizado

incluiu 138 controles e 862 casos, incorporando interações genéticas aditivas e não-aditivas. Embora a aplicação do SMS tenha representado uma inovação na análise de problemas de classificação, o desempenho foi inferior ao observado em simulações voltadas para regressão (fenótipo medido por variável contínua). Essa limitação pode ser explicada por fatores como o desbalanceamento das classes, o não uso de validação cruzada estratificada no *Support Vector Machine* (SVM) usado na previsão do fenótipo binário, a ausência de técnicas específicas no SMS para lidar com esse problema e a maior suscetibilidade a ruídos nos dados de treinamento. Esses aspectos comprometeram a capacidade do SMS de identificar instâncias da classe rara e, conseqüentemente, reduziram sua eficácia geral.

Para contornar os desafios apresentados por datasets desbalanceados, diversas abordagens têm sido propostas. Técnicas de re-amostragem, como sub-amostragem da classe majoritária e super-amostragem da classe minoritária, têm se mostrado promissoras. Além disso, o uso de métricas alternativas, como acurácia, precision, recall e F1-score, são fundamentais para avaliar de forma mais representativa o desempenho dos modelos em cenários desbalanceados (HE; GARCIA, 2009).

Outro aspecto importante é a validação cruzada, que contribui para uma avaliação mais robusta do modelo ao reduzir a variabilidade associada a um único conjunto de treinamento e teste. Métodos como validação cruzada estratificada são particularmente eficazes em datasets desbalanceados, pois garantem que a proporção das classes seja mantida em cada subdivisão do conjunto de dados (KOHAVI, 1995). Essa técnica auxilia na estimativa da generalização do modelo em cenários reais, oferecendo resultados mais consistentes em relação à sua performance em dados nunca vistos.

Diante disso, os resultados deste trabalho são significativos nas áreas da Matemática e Ciências Biológicas, uma vez que utiliza-se de métodos e técnicas matemáticas, estatísticas e computacionais para se tornar possível testar um grande número de marcadores e associá-los a características diversas podendo ocasionar contribuições nas áreas em destaque.

3 Problema

Estudos de associação em escala genômica são realizados com o objetivo de encontrar SNPs que marcam regiões no genoma dos seres vivos que influenciam determinadas características, logo, há uma busca por genes responsáveis por variações fenotípicas. No entanto, muitos são os problemas que rodeiam esse estudo como por exemplo o número elevado de marcadores, a amostra de indivíduos que pode ser pequena, havendo assim um desequilíbrio que elimina a possibilidade de uso de diversos modelos de regressão estatísticos e de aprendizado de máquina, e a seleção de SNPs quando existe interação entre duplas ou trios de SNPs que podem estar associados ao fenótipo em questão.

Nos casos onde o número de marcadores no genoma é elevado, muitos deles podem estar correlacionados entre si, contudo não significa que a correlação existente indique que o SNP selecionado é a causa do fenótipo em questão.

Por outro lado, a amostra de indivíduos pode ser pequena o que reduz a variabilidade dos marcadores e assim diminui o poder de detecção da associação entre o SNP e a característica fenotípica.

Há também um grande desafio de seleção de SNPs quando existe a ocorrência de interação entre duplas e trios de SNPs que podem estar associados ao fenótipo avaliado. Com isso, métodos baseados em modelos lineares não identificam os sinais de associação gerados pelas interações. Desta forma, a busca por abordagens que contemplem capturar efeitos não lineares é de suma importância.

A partir dos problemas citados e como o SMS proposto por Oliveira (2015) ainda seleciona SNPs não causais além de não selecionar todos os SNPs causais, é de suma importância buscar por melhorias em todas as etapas. Portanto, estudar novos critérios de otimalidade ou seleção, pode reduzir o número de SNPs falsos-positivos e, simultaneamente, aumentar a quantidade de verdadeiros-positivos. Com isso, apresentaremos um método já existente designado por ***SNP Markers Selector (SMS)***, porém com novos critérios de otimalidade para

classificação binária, visto que há a possibilidade de obtermos uma melhoria significativa no processo de seleção dos SNPs.

4 Objetivos

Será evidenciado abaixo os principais objetivos que este trabalho planeja alcançar.

4.1 Objetivo Geral

O principal objetivo deste trabalho é modificar o método SMS com a introdução novos critérios de otimalidade para a seleção de marcadores genéticos relacionados a um certo tipo de fenótipo mapeado por uma variável discreta binária. Este cenário é particularmente desafiador devido à natureza desbalanceada dos dados, em que uma das categorias da variável binária é consideravelmente menos representada. A partir de um conjunto de dados com uma grande quantidade de marcadores genéticos, serão priorizados aqueles que apresentam efeitos marginais significativos e/ou interação de forma relevante em duplas e trios, com o objetivo de identificar SNPs verdadeiros-positivos e reduzir falsos-positivos.

4.2 Objetivos Específicos

Os objetivos específicos são:

- Apresentar o método SMS em sua versão atual com o critério de otimalidade baseada na área abaixo da curva ROC;
- Apresentar uma versão atualizada do SMS baseada em novos critérios de otimalidade denominados *Precision*, *Recall* e F1-score;
- Verificar se o método SMS com o F1-score terá um desempenho superior ao método SMS com a área abaixo da curva ROC (AUC);
- Avaliar o desempenho dos critério de otimalidade usando validação de dados estratificada e técnicas de balanceamento dos dados.

5 Embasamento Teórico

Os estudos de associação em escala genômica ampla (GWAS) visam facilitar a busca por marcadores genéticos associados a fenótipos de interesse usando métodos matemáticos para identificar certas variações no genoma.

Para a execução do GWAS é necessária a seleção de indivíduos a partir de uma população de acordo com uma característica específica. Após a seleção dessa característica faz-se a comparação do DNA dos indivíduos que possuem o fenótipo de interesse.

As tabelas 1 e 2 abaixo apresentam um exemplo de como uma base de dados é gerada em estudos de GWAS.

Após a seguinte codificação: $aa = 0$, $Aa = 1$ e $AA = 2$, ou seja, no SNP de cada indivíduo é contado o número de alelos A , tem-se a base de dados codificada mostrada na tabela a seguir.

Nesta seção apresentaremos os métodos de seleção de SNPs e os critérios de otimalidade que serão abordados neste trabalho.

5.1 Métodos de seleção de marcadores genéticos

5.1.1 Valor-p bruto

O método mais comumente usado em estudos de associação em escala genômica é baseado no valor-p de algum tipo de teste de hipótese. O valor-p (do inglês, *p-value*) varia entre 0 e 1 e consiste na ideia de se calcular, supondo que a hipótese inicial nula seja verdadeira, a probabilidade de se obter um valor da estatística de teste

Tabela 1 – Exemplo de base de dados em GWAS com fenótipo binário (classificação) sem codificação no genótipo.

	SNP 1	SNP 2	SNP 3	SNP 4	SNP 5	SNP 6	SNP 7	SNP 8	Fenótipo
Indivíduo 1	aa	Aa	AA	Aa	AA	aa	AA	Aa	1
Indivíduo 2	Aa	AA	AA	Aa	aa	Aa	AA	Aa	0
Indivíduo 3	AA	aa	aa	aa	AA	Aa	aa	Aa	0
Indivíduo 4	aa	Aa	aa	AA	Aa	aa	aa	AA	0
Indivíduo 5	Aa	Aa	aa	AA	aa	Aa	AA	Aa	1
Indivíduo 6	AA	AA	Aa	Aa	Aa	Aa	aa	Aa	1
Indivíduo 7	Aa	Aa	Aa	aa	AA	aa	Aa	AA	0
Indivíduo 8	aa	aa	AA	Aa	Aa	Aa	Aa	Aa	0
Indivíduo 9	AA	Aa	aa	Aa	aa	AA	Aa	AA	0
Indivíduo 10	aa	AA	Aa	Aa	Aa	aa	AA	Aa	0

Tabela 2 – Exemplo de base de dados em GWAS com fenótipo binário (classificação) com codificação no genótipo.

	SNP 1	SNP 2	SNP 3	SNP 4	SNP 5	SNP 6	SNP 7	SNP 8	Fenótipo
Indivíduo 1	0	1	2	1	2	0	2	1	1
Indivíduo 2	1	2	2	1	0	1	2	1	0
Indivíduo 3	2	0	0	0	2	1	0	1	0
Indivíduo 4	0	1	0	2	1	0	0	2	0
Indivíduo 5	1	1	0	2	0	1	2	1	1
Indivíduo 6	2	2	1	1	1	1	0	1	1
Indivíduo 7	1	1	1	0	2	0	1	2	0
Indivíduo 8	0	0	2	1	1	1	1	1	0
Indivíduo 9	2	1	0	1	0	2	1	2	0
Indivíduo 10	0	2	1	1	1	0	2	1	0

maior ou igual do que aquela fornecida por uma amostra (FERREIRA; PATINO, 2015). Portanto, pode-se entender que o valor-p verifica quão bem os dados da amostra apoiam o argumento de que a hipótese nula é verdadeira. Geralmente, o nível de significância, denominado α , para a hipótese nula H_0 é de 0,05, ou seja, de 5%. Se o valor-p for menor ou igual ao valor de α adotado, então tem-se que a hipótese nula é inconsistente o que nos leva a uma hipótese alternativa sendo verdadeira, do contrário os dados obtidos pela amostra validam que a hipótese nula é verdadeira (OLIVEIRA, 2015).

O valor-p é calculado em situações distintas. Neste trabalho, ele será obtido a partir do modelo de regressão logística. Esse método consiste em construir uma relação estatística entre uma variável independente e uma variável dependente binária. O modelo de regressão logística baseado em uma população é dado pela Expressão 1, onde y representa a variável resposta binária (por exemplo, presença ou ausência de uma característica), x é a variável explicativa e ϵ é o erro estocástico. Os coeficientes β_0 e β_1 representam os parâmetros do modelo.

$$\log \left(\frac{P(y = 1|x)}{1 - P(y = 1|x)} \right) = \beta_0 + \beta_1 x + \epsilon \quad (1)$$

Como a maioria dos estudos é baseada em amostras e não em populações, a Expressão 2 abaixo traz o modelo de regressão logística amostral, onde i varia de 1 a n .

$$\log \left(\frac{P(y = 1|x)}{1 - P(y = 1|x)} \right) = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\epsilon}_i \quad (2)$$

Para GWAS com fenótipo binário, um exemplo de relação entre um SNP e o fenótipo é dado pelo método da máxima verossimilhança. O objetivo é estimar os parâmetros β_0 e β_1 de forma a maximizar a verossimilhança dos dados observados. A função de verossimilhança para n observações é dada por:

$$L(\beta_0, \beta_1) = \prod_{i=1}^n P(y_i | x_i)^{y_i} (1 - P(y_i | x_i))^{1-y_i} \quad (3)$$

Aplicando o método da máxima verossimilhança e resolvendo numericamente as equações resultantes, obtemos as estimativas $\hat{\beta}_0$ e $\hat{\beta}_1$, que permitem calcular as probabilidades associadas a diferentes valores de x .

Um modelo de regressão logística simples é construído a partir do método de máxima verossimilhança e um teste de hipóteses é realizado sobre o coeficiente $\hat{\beta}_1$ para verificar se esse coeficiente é estatisticamente diferente de zero (H_0), dado um nível de significância α . Nesse contexto, o valor-p é utilizado para avaliar a significância estatística. As hipóteses nula (H_0) e alternativa (H_α) são dadas pelas Expressões 4 e 5 abaixo

$$H_0 = 0 \quad (4)$$

$$H_\alpha \neq 0 \quad (5)$$

O valor-p associado aos testes de hipóteses dados pelas Expressões 4 e 5 é usado como um método baseado em filtro para escolher os SNPs mais associados ao fenótipo colocado em questão.

A partir da observação de que quanto menor é o valor-p do coeficiente linear do modelo de regressão, mais significativo estatisticamente é a associação entre o SNP e o fenótipo, ordenam-se os SNPs em ordem crescente de valores-p e selecionam-se somente os SNPs abaixo do limite de 5 % que é o nível de significância mais comumente adotado. Como $-\log_{10}(x)$ é maior que zero para valores de x entre 0 e 1, além de ser uma função decrescente, aplica-se esta transformação aos valores-p dos SNPs para uma melhor visualização gráfica em duas dimensões.

A Figura 2 ilustra o Gráfico de Manhattan usado no estudo GWAS, que mostra diferentes SNPs em diferentes cromossomos, no eixo horizontal com seus respectivos valores-p na escala $-\log_{10}(p)$ no eixo vertical. A linha pontilhada representa o limite de 5 % para a seleção dos SNPs, transformado para a escala $-\log_{10}(0,05)$.




Figura 2 – Gráfico de Manhattan onde a linha vermelha horizontal representa o limite para a significância de todo um genoma.

Gráfico retirado de Demontis et al. (2019)

5.1.2 Valor-p ajustado

O valor-p ajustado para uma hipótese em especial dentro de um conjunto de hipóteses é o menor nível de significância em que a hipótese escolhida é rejeitada (SANTOS, 2013). Ou seja, o valor-p ajustado representa a menor taxa de erro em que uma hipótese nula específica será descartada.

O valor-p ajustado geralmente é mais preciso que o valor-p bruto, com isso, ele se torna mais restritivo, isto é, ele seleciona os SNPs mais informativos e tenta eliminar ao máximo os que não se relacionam com o fenótipo em questão.

Para os cálculos do valor-p ajustado utiliza-se a chamada correlação de Bonferroni, multiplicando o valor-p bruto pelo número de SNPs (número de testes feitos). Logo após os cálculos é necessário selecionar os SNPs cujos valores-p são menores que o α escolhido (OLIVEIRA, 2015).

5.1.3 SNP Markers Selector (SMS)

Este modelo se divide em três etapas distintas, a primeira referente à análise de relevância dos marcadores genéticos, a segunda é uma estratégia de corte que será responsável pela definição do conjunto de marcadores que serão utilizados e a terceira responsável pelo refinamento da segunda fase com o objetivo de eliminar o máximo possível de marcadores falsos-positivos. Essas três etapas serão implementadas utilizando, respectivamente, as Florestas Aleatórias (RF, do inglês *Random Forest*), Máquina de Vetores Suporte (SVM, do inglês *Support Vector Machine*) e Algoritmos Genéticos (GA, do inglês *Genetic Algorithm*) (OLIVEIRA, 2015).

Para a primeira etapa, a ordenação baseada na RF é feita por cromossomo, não considerando os marcadores de todos os cromossomos ao mesmo instante. Os subconjuntos dos SNPs são formados de modo crescente e contínuo, sendo avaliados em cada cromossomo. O objetivo desta etapa consiste em fazer um rank de todas as variáveis.

Já na segunda etapa, a primeira seleção é feita a partir da maior área abaixo da curva ROC (AUC) ocasionado pelo SVM aplicado ao *rank* da RF, com o objetivo de escolher SNPs mais promissores, ou seja, aqueles que tem relação com o fenótipo de interesse.

Na a última etapa, a união dos subgrupos dos SNPs por cromossomo é executada, estabelecendo o tamanho do cromossomo utilizado na otimização do GA. No GA, a função de aptidão, aquela que quantifica a qualidade genética dos cromossomos do GA que são subconjuntos de SNPs, é baseada na área abaixo da curva ROC (AUC).

Portanto, este método tem como principal objetivo maximizar o potencial de seleção a partir das três etapas descritas acima, a Figura 3 esclarece como cada etapa é realizada, onde *CQ* representa filtros específicos aplicados à base de dados inicial para o controle de qualidade.




Figura 3 – Fluxograma das etapas do SMS

Gráfico retirado de Oliveira (2015)

5.2 Critérios de otimalidade

5.2.1 Acurácia

A acurácia é uma métrica amplamente utilizada para avaliar o desempenho de modelos de classificação. Ela mede a proporção de previsões corretas em relação ao total de previsões realizadas, considerando todas as classes de um problema. Ela responde à pergunta: Qual a proporção de previsões corretas feitas pelo modelo em relação ao total de exemplos avaliados?

$$acurácia = \frac{VP + VN}{VP + VN + FP + FN} \quad (6)$$

Para compreender melhor essa métrica, é essencial utilizar a matriz de confusão, ela organiza os resultados das previsões do modelo de maneira estruturada, fornecendo uma visão clara sobre os acertos e erros, bem como as diferentes formas de classificação incorreta.

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

Figura 4 – Matriz de confusão
(NOGARE, 2020)

Embora a acurácia seja uma métrica intuitiva e fácil de calcular, sua aplicação deve ser feita com cuidado, especialmente em problemas de classificação com classes desbalanceadas. Em cenários onde uma das classes é dominante, a acurácia pode apresentar resultados enganosos, sugerindo um bom desempenho mesmo que o modelo tenha baixo desempenho na classificação da classe minoritária.

5.2.2 Precision

A métrica *precision* (precisão) é amplamente utilizada para avaliar modelos de classificação, especialmente em contextos onde as classes de interesse são desbalanceadas. Ela indica a precisão do modelo ao prever as instâncias de uma classe positiva, ou seja, a proporção de verdadeiros positivos entre todas as instâncias classificadas como positivas.

$$precision = \frac{VP}{VP + FP} \quad (7)$$

Onde, VP (Verdadeiros Positivos) é o número de instâncias corretamente classificadas como positivas e FP (Falsos Positivos) é número de instâncias incorretamente classificadas como positivas. Esse cálculo foca nas predições feitas pelo modelo, levando em consideração o erro quando o modelo erroneamente classifica uma instância negativa como positiva.

É importante notar que a precisão por si só pode ser enganosa e não dar uma visão completa do desempenho do modelo. Por exemplo, um modelo com alta precisão pode ter uma revocação baixa, o que significa que ele está deixando muitos exemplos positivos “escaparem” (SOUZA, 2025). Por isso, é importante avaliar o desempenho do modelo usando múltiplas métricas.

5.2.3 Recall

O *Recall* (Revocação ou Sensibilidade ou *True Positive Rate* - TPR) tem como objetivo medir a capacidade do modelo de identificar corretamente todas as instâncias positivas dentro de um conjunto de dados. De forma simples, o *recall* quantifica a proporção de casos positivos que foram efetivamente identificados pelo modelo, comparado ao total de casos positivos reais. Ele responde à pergunta: entre todos os exemplos realmente positivos, quantos foram identificados corretamente?

$$Recall = \frac{VP}{VP + FN} \quad (8)$$

Onde, VP (Verdadeiros Positivos) são os casos que o modelo previu como positivos e realmente são positivos e FN (Falsos Negativos) são os casos que o modelo previu como negativos, mas realmente são positivos. Essa métrica é particularmente importante em contextos onde o custo de não detectar uma instância positiva é alto.

No entanto, o *recall* não leva em consideração a quantidade de falsos positivos, o que significa que um modelo pode alcançar um alto valor de *recall* ao classificar todas as instâncias como positivas, mas isso não seria ideal, pois geraria um grande número de falsos positivos.

5.2.4 Exemplo de Alta *Precision* e Baixa *Recall*

Este exemplo explica por que um modelo pode ter alta *Precision* (precisão) mas, ao mesmo tempo, baixa *Recall* (revocação ou sensibilidade), utilizando o exemplo de um filtro de e-mails que separa *spam* (mensagens indesejadas) das mensagens legítimas.

Suponha que você tenha 200 e-mails na sua caixa de entrada. Desses:

- 100 e-mails são realmente **spam** (positivos).
- 100 e-mails são legítimos (negativos).

Um modelo de classificação (filtro de *spam*) faz as seguintes previsões:

- Marca 11 e-mails como *spam*.
- Desses 11 e-mails, 10 são realmente *spam* (Verdadeiros Positivos, *VP*) e 1 é legítimo (Falso Positivo, *FP*).

Sabemos que, ao todo, existem 100 e-mails *spam*. O filtro, portanto, capturou apenas 10 desses 100, deixando 90 *spams* passarem sem serem identificados (Falsos Negativos, *FN*).

A precisão mede a proporção de e-mails que o modelo classifica como *spam* e que, de fato, são *spam*:

$$Precision = \frac{\text{Verdadeiros Positivos (VP)}}{\text{Verdadeiros Positivos (VP)} + \text{Falsos Positivos (FP)}} = \frac{10}{10 + 1} = \frac{10}{11} \approx 90,9\%.$$

A *Recall* mede a proporção de *spams* que o modelo conseguiu recuperar, ou seja, dos e-mails realmente *spam*, quantos foram corretamente classificados como *spam*:

$$Recall = \frac{\text{Verdadeiros Positivos (VP)}}{\text{Verdadeiros Positivos (VP)} + \text{Falsos Negativos (FN)}} = \frac{10}{10 + 90} = \frac{10}{100} = 10\%.$$

- **Alta Precisão** ($\approx 90,9\%$): Sempre que o filtro *diz* que um e-mail é *spam*, ele quase sempre acerta. Em outras palavras, há poucos falsos positivos.
- **Baixa Revocação** (10%): O filtro deixa passar muitos *spams* (90 de um total de 100). Portanto, ele falha em capturar a maior parte das mensagens indesejadas.

Este exemplo mostra que, apenas com uma *precision* alta, não podemos concluir que um classificador seja “bom”, pois se ele falha em recuperar a maior parte dos *spams* (baixa *recall*), isso significa que muitos e-mails indesejados não estão sendo filtrados.

O caso de “alta precisão e baixa revocação” evidencia a importância de avaliar múltiplas métricas de desempenho de um modelo, pois depender apenas de uma única métrica (como a precisão) pode ser enganoso em cenários em que capturar a maioria dos casos positivos é fundamental (como no filtro de *spam*, detecção de fraudes, diagnósticos médicos, etc.).

5.2.5 F1-score

O F1-score é uma métrica particularmente útil quando se busca um equilíbrio entre a *precision* e o *recall* de um modelo, sendo o ideal quando há uma preocupação em minimizar tanto os falsos positivos quanto os falsos negativos. É a média harmônica entre a *precision* e o *recall*. Ele responde a pergunta: Qual é o equilíbrio entre a *precision* e o *recall* do modelo?

$$F1 = \frac{1}{\frac{1}{2} \left(\frac{1}{precision} + \frac{1}{recall} \right)} = 2 \cdot \frac{precision \cdot recall}{precision + recall} \quad (9)$$

O F1-score varia de 0 a 1, onde 1 indica o melhor desempenho possível, e 0 indica um desempenho muito ruim. Uma das vantagens sobre outras métricas, é que ele não é afetado por desequilíbrios nas classes. Isso ocorre porque o F1-score considera tanto os falsos positivos quanto os falsos negativos, permitindo avaliar o desempenho de um modelo de forma mais justa e completa.

5.2.6 A Área Sob a Curva ROC

A Curva Característica de Operação do Receptor (*Receiver Operating Characteristic*, ROC) é uma ferramenta amplamente utilizada para avaliar a performance de modelos de classificação binária. Ela é construída ao plotar a taxa de verdadeiros positivos (*True Positive Rate*, TPR) contra a taxa de falsos positivos (*False Positive Rate*, FPR) para diferentes valores de limiar de decisão. A área sob essa curva, conhecida como AUC (*Area Under the Curve*), representa uma métrica resumida da capacidade do modelo em separar as classes. Assim, na tentativa de simplificar a análise da ROC, a AUC nada mais é que uma maneira de resumir a curva ROC em um único valor, agregando todos os limiares da ROC, calculando a “área sob a curva”.




Figura 5 – ROC e AUC de um modelo hipotético perfeito.

Gráfico retirado de (GOOGLE, 2023)

Matematicamente, a AUC pode ser definida como a probabilidade de que um modelo classifique corretamente uma observação positiva como mais provável de pertencer à classe positiva do que uma observação negativa ((HANLEY; MCNEIL, 1982).

$$AUC = \int_0^1 TPR(FPR) d(FPR) \quad (10)$$

A AUC varia entre 0 e 1. Um modelo com $AUC = 0,5$ indica performance semelhante ao acaso, enquanto AUC próxima de 1 indica excelente capacidade de separação entre as classes. Contudo, é importante notar que a AUC não considera o custo relativo de falsos positivos e falsos negativos, o que pode limitar sua aplicabilidade em cenários com classes desbalanceadas ou custos assimétricos (SAITO; REHMSMEIER, 2015).

5.2.7 Validação Cruzada

A validação cruzada (ou *cross-validation*) é utilizada para estimar a eficácia de um modelo e prevenir o sobreajuste (*overfitting*). Ela consiste em dividir os dados disponíveis em múltiplos subconjuntos, treinando e testando o modelo em diferentes combinações desses subconjuntos. Esse processo garante uma avaliação mais robusta do desempenho do modelo, minimizando o viés e proporcionando uma melhor generalização dos resultados (JAMES et al., 2013). Ela responde à pergunta: Qual é a capacidade de generalização do modelo em dados não vistos?

A forma mais comum de validação cruzada é a *k-fold cross-validation*. Nesse método, o conjunto de dados é dividido em k subconjuntos de tamanhos aproximadamente iguais. O modelo é treinado k vezes, cada vez utilizando $k - 1$ subconjuntos para treinamento e o subconjunto restante para teste. O desempenho do modelo é então avaliado como a média dos resultados obtidos em cada iteração.

Em muitos problemas práticos de aprendizado de máquina, especialmente em tarefas de classificação, os dados podem ser desbalanceados. Em situações como essas, a validação cruzada convencional pode não ser a melhor abordagem, pois o modelo pode ser treinado e testado em subconjuntos onde as classes estão desproporcionalmente representadas. A validação cruzada estratificada resolve esse problema, assim como na validação cruzada tradicional, ela divide o conjunto de dados em k subconjuntos. A principal diferença é que, ao realizar essa divisão, cada subconjunto é feito de maneira que a proporção de cada classe nos subconjuntos seja o mais próxima possível da proporção existente no conjunto de dados original. Sua aplicação correta proporciona uma boa medida de como o modelo pode se comportar em dados reais e não vistos, ajudando a identificar o melhor modelo para a tarefa em questão.

5.3 Técnicas de balanceamento de dados

5.3.1 Oversampling

O *oversampling* (Super-amostragem) consiste na geração artificial de novos exemplos da classe minoritária, tornando o conjunto de dados mais equilibrado. Uma abordagem comum é a simples replicação das instâncias existentes, contudo, essa estratégia pode levar ao sobreajuste do modelo. Para evitar esse problema, métodos como o *Synthetic Minority Over-sampling Technique* (SMOTE) são amplamente utilizados. O SMOTE gera novos exemplos sintéticos a partir da interpolação entre instâncias reais da classe minoritária, reduzindo o risco de sobreajuste e melhorando a capacidade de generalização do modelo (FERNANDES et al., 2021).

Outra variação do *oversampling* é o ADASYN (*Adaptive Synthetic Sampling*), que aprimora o SMOTE ao focar em gerar exemplos sintéticos nas regiões onde a classe minoritária é mais escassa, melhorando ainda mais a distribuição do conjunto de dados. Estudos demonstram que técnicas de *oversampling* podem melhorar significativamente o desempenho de modelos preditivos em cenários de dados desbalanceados (BUNKHUMPORNCHAI; KHEAOKAEW, 2022).

5.3.2 Undersampling

O *undersampling* (Sob-amostragem) consiste em manter todos os dados da classe minoritária e remover aleatoriamente instâncias da classe majoritária, reduzindo o desequilíbrio, mas potencialmente descartando informações relevantes. Para minimizar essa perda de informação, métodos mais sofisticados, como o *NearMiss* e o *Tomek Links*, são utilizados para selecionar estrategicamente quais instâncias devem ser removidas (ZHANG; LIU, 2021).

O método *NearMiss* seleciona instâncias da classe majoritária com base na sua distância para as instâncias da classe minoritária, garantindo que os dados restantes preservem informações importantes para a classificação. Já os *Tomek Links* identificam pares de instâncias de classes opostas que estão muito próximas e removem a instância da classe majoritária, melhorando a separabilidade entre as classes.

Embora o *undersampling* possa melhorar a capacidade do modelo de aprender padrões relevantes da classe minoritária, ele também pode reduzir a variabilidade dos dados e prejudicar a capacidade de generalização do modelo.

6 Metodologia

6.1 Método proposto

Com tudo que foi exposto, o método proposto para este trabalho visa utilizar o método SMS adaptado para GWAS com fenótipo medido por variável binária (problema de classificação) com novos critérios de otimalidade para classificação binária, para a seleção de marcadores genéticos relacionados a fenótipos específicos indo atrás de SNPs verdadeiramente informativos e buscando sempre reduzir os não explicativos.

Serão utilizados os métodos de seleção de SNPs do valor-p, valor-p ajustado, baseados na Regressão Logística entre o SNP em questão e o fenótipo, e o SMS de Oliveira (2015) como métodos de comparação com o método proposto, com o objetivo de verificar a eficiência dos novos critérios de otimalidade para classificação tais como *Acurácia*, *Precision*, *Recall*, *F1 - Score* e *AUC*.

6.2 Implementação computacional do método SMS modificado

O SMS modificado com os novos critérios de otimalidade será implementado na linguagem R (TEAM et al., 2013). As bases de dados serão simuladas pelo pacote SCRIME (SCHWENDER; FRITSCH, 2013) do software R (TEAM et al., 2013). Para a implementação das três etapas do SMS serão utilizados os pacotes: *RandomForest* do R, para a floresta aleatória, *e1071* do R para o SVM e o pacote *GA* do R para o algoritmo genético.

7 Resultados Esperados

Os principais resultados esperados para este trabalho são:

- Obter um aperfeiçoamento do método de seleção de marcadores genéticos relacionados a certos fenótipos com a substituição do critério de otimalidade em cenários complexos com interação entre duplas e trios de SNPs juntamente com marcadores que possuem efeitos marginais significativos;
- Selecionar mais SNPs verdadeiros-positivos e eliminar o máximo possível de falsos-positivos;
- Conclusão do TCC.

8 Cronograma

Sabe-se que o objetivo deste trabalho é obter um aperfeiçoamento do método de seleção a partir da introdução de novos critérios de otimalidade para a seleção de SNPs relacionados a um certo fenótipo binário (classificação),

para isso o cronograma segue a seguinte forma:

- 1) Aprofundamento do referencial teórico;
- 2) Implementação do método SMS com os novos critérios de otimalidade para classificação;
- 3) Criação das bases simuladas pelo simulador SCRIME do software R;
- 4) Execução do SMS com novos critérios de otimalidade para classificação sobre as bases de dados simuladas na etapa anterior;
- 5) Comparação dos resultados obtidos com o SMS original proposto por Oliveira (2015) e com métodos baseados nos valores-p bruto e corrigido;
- 6) Conclusão e trabalhos futuros.

Etapas	Cronograma TCC				
	Março	Abril	Maio	Junho	Julho
1	X	X			
2		X			
3			X		
4			X		
5				X	
6					X

Tabela 3 – Cronograma do TCC

Referências

- BROOKES, A. J. The essence of snps. *Gene*, Elsevier, v. 234, n. 2, p. 177–186, 1999.
- BUNKHUMPORNCHAI, W.; KHEAOKAEW, W. A comparative study of oversampling techniques for imbalance learning. *Expert Systems with Applications*, v. 187, p. 115950, 2022.
- BUSH, W. S.; MOORE, J. H. Genome-wide association studies. *PLOS Computational Biology*, Public Library of Science, v. 8, n. 12, p. e1002822, 2012.
- DEMONTIS, D. et al. Discovery of the first genome-wide significant risk loci for attention deficit/hyperactivity disorder. *Nature genetics*, Nature Publishing Group, v. 51, n. 1, p. 63–75, 2019.
- FERNANDES, K. et al. Interpretable oversampling with counterfactual explanations. *International Journal of Data Science and Analytics*, v. 11, n. 3, p. 223–239, 2021.
- FERREIRA, J. C.; PATINO, C. M. O que realmente significa o valor-p? *Jornal Brasileiro de Pneumologia*, SciELO Brasil, v. 41, p. 485–485, 2015.
- GOOGLE. *Área sob a curva (AUC)*. 2023. Disponível em: [https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=pt-br#:~:text=modelo%20hipot%C3%A9tico%20perfeito.,%C3%81rea%20sob%20a%20curva%20\(AUC\),AUC\)%20de%201%2C0](https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc?hl=pt-br#:~:text=modelo%20hipot%C3%A9tico%20perfeito.,%C3%81rea%20sob%20a%20curva%20(AUC),AUC)%20de%201%2C0).
- HANLEY, J. A.; MCNEIL, B. J. The meaning and use of the area under a receiver operating characteristic (roc) curve. *Radiology*, v. 143, n. 1, p. 29–36, 1982.
- HE, H.; GARCIA, E. A. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, IEEE, v. 21, n. 9, p. 1263–1284, 2009.
- JAMES, G. et al. *An Introduction to Statistical Learning: with Applications in R*. [S.l.]: Springer, 2013.

- KOHAVERI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. Montreal, p. 1137–1145, 1995.
- KRAWCZYK, B. Learning from imbalanced data: Open challenges and future directions. *Progress in Artificial Intelligence*, Springer, v. 5, n. 4, p. 221–232, 2016.
- LAIRD, N. M.; LANGE, C. *The fundamentals of modern statistical genetics*. [S.l.]: Springer Science & Business Media, 2010.
- LO, A. et al. Why significant variables aren't automatically good predictors. *Proceedings of the National Academy of Sciences*, National Acad Sciences, v. 112, n. 45, p. 13892–13897, 2015.
- NOGARE, D. *Performance de Machine Learning: Matriz de Confusão*. 2020. Disponível em: <https://diegonogare.net/2020/04/performance-de-machine-learning-matriz-de-confusao/>.
- OLIVEIRA, F. C. de. *Um método para seleção de atributos em dados genômicos*. Tese (Doutorado) — Universidade Federal de Juiz de Fora, 2015.
- SAITO, T.; REHMSMEIER, M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLoS One*, v. 10, n. 3, p. e0118432, 2015.
- SANTOS, D. d. S. *Comparações múltiplas para dados censurados*. Tese (Doutorado) — Universidade de São Paulo, 2013.
- SCHWENDER, H.; FRITSCH, A. scribe: analysis of high-dimensional categorical data such as snp data. *R package version*, v. 1, n. 3, 2013.
- SETIAWAN, D.; KUSUMA, W. A.; WIGENA, A. H. Snp selection using variable ranking and sequential forward floating selection with two optimality criteria. *Journal of Engineering Science & Technology Review*, v. 11, n. 5, 2018.
- SOUZA, I. Conheça as métricas mais importantes para avaliar classificadores em machine learning. 2025. Acessado em: 20 jan. 2025. Disponível em: <https://medium.com/@igor1245souza/conhe%C3%A7a-as-m%C3%A9tricas-mais-importantes-para-avaliar-classificadores-em-machine-learning-bd270602f317#:~:text=Existem%20v%C3%A1rias%20m%C3%A9tricas%20que%20podem,mais%20apropriada%20para%20determinados%20cen%C3%A1rios>.
- TEAM, R. C. et al. R: A language and environment for statistical computing. Vienna, Austria, 2013.
- VISSCHER, P. M. et al. 10 years of gwas discovery: Biology, function, and translation. *The American Journal of Human Genetics*, Elsevier, v. 101, n. 1, p. 5–22, 2017.
- WELTER, D. et al. The nhgri gwas catalog, a curated resource of snp-trait associations. *Nucleic acids research*, Oxford University Press, v. 42, n. D1, p. D1001–D1006, 2014.
- ZHANG, C.; LIU, C. A comprehensive study on undersampling methods for class imbalance. *Journal of Machine Learning Research*, v. 22, p. 1–30, 2021.